

Johann Wolfgang Goethe-Universität Frankfurt am Main
Fachbereich 12 Mathematik/ Institut für Mathematik
Studiengang Mathematik (Bsc.)

**Bachelorarbeit im Bereich Stochastische Analyse von
Algorithmen**

Preferential attachment Trees



Victor Velesco
Matrikelnummer: 7419816
Fachsemester: 8
Betreuender Professor: Prof. Dr. Ralph Neininger
Zweitgutachter: Jasper Ischebeck

Selbstständigkeitserklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbstständig angefertigt, nicht anderweitig zu Prüfungszwecken vorgelegt und keine anderen als die angegebenen Hilfsmittel verwendet habe. Sämtliche wissentlich verwendete Textausschnitte, Zitate oder Inhalte anderer Verfasser wurden ausdrücklich als solche gekennzeichnet.

.....

(Ort, Datum)

.....

(Unterschrift)

Inhaltsverzeichnis

1	Einführung	3
1.1	Motivation	3
1.2	Definitionen	3
1.3	Kingman Paintbox representation	5
1.4	Chinese Restaurant Process	7
1.5	Verallgemeinerte CRP	8
2	Linear preferential trees	13
2.1	Konstruktion von general preferential trees	13
2.2	Konstruktion von Split Bäumen	15
3	Anwendungen	18
4	m-ary increasing trees	22

Einführung

Die vorliegende Bachelorarbeit ist eine Ausarbeitung von der wissenschaftlichen Publikation „Random Recursive Trees and Preferential Attachment Trees are Random Split Trees“, von Svante Janson [6].

Die Publikation von Janson verallgemeinert die von Devroye [4] eingeführten *Split trees*, indem zusätzlich Bäume mit unendlichen Ausgangsgraden, also Anzahl von Kindern pro Wurzel, zugelassen werden. Präziser formuliert, werden sogenannte *Linear Preferential Attachment Trees* in die Vorlage der Split-Bäume aufgenommen. Je nach Parameter Wahl umfassen die *Preferential Trees* unter anderem die *m-ary*, *standard preferential* und *zufälligen rekursiven* Bäume und Eigenschaften der jeweiligen Bäume werden in Kapiteln 3 und 4 näher betrachtet. Da die Publikation stark auf *Kingman's theory of exchangeable partitions* [8,9] als auch auf *Pitman's chinese restaurant process* [11,12] beruht, wird im ersten Kapitel ein Überblick über diese Themengebiete verschaffen. Anschließend wird das Haupttheorem zur Einbettung in Kapitel 2 bewiesen, gefolgt von einer Anwendung zu Tiefen in Kapitel 3. Im letzten Kapitel wird ein Spezialfall der *Preferential Trees* gesondert behandelt.

1.1 Motivation

Als vorläufige Motivation für die Relevanz der Theorie der austauschbaren und partiell austauschbaren Partitionen von $\mathbb{N}$ für die darauffolgende Baumanalyse, beschreiben wir kurz informell den Zusammenhang. Die Konstruktion von Bäumen die betrachtet werden, basiert auf sukzessives Hinzufügen von Knoten, welche dann mit natürlichen Zahlen identifiziert werden. Diese Art von Bäumen in disjunkte Teilbäume aufzuteilen, kann man sich deshalb als eine Art Partition vorstellen. Die Austauschbarkeit erlaubt uns eine De-Finetti-ähnliche Aussage (Satz 1.8) über die relative Größe von Partitionen und somit über die Größe von Teilbäumen zu formulieren.

Wir beginnen mit den Definitionen.

1.2 Definitionen

Definition 1. Sei F eine endliche Menge. Dann ist eine Partition von F eine ungeordnete Sammlung von nichtleeren, disjunkten Untermengen $\{A_i | 1 \leq i \leq k, A_i \subseteq F\}$, mit $\bigcup_{i=1}^k A_i = F$.

Eine Partition von einer natürlichen Zahl n , ist eine ungeordnete Menge von positiven natürlichen Zahlen mit Summe n .

Definition 2. (Zufällige Partitionen)

1. Eine zufällige Partition von $n \in \mathbb{N}$ ist eine Zufallsvariable σ_n mit Werten in der endlichen Menge von allen Partitionen von n .
2. Eine zufällige Partition von $[n] := \{1 \dots n\}$, ist eine Zufallsvariable Π_n mit Werten in $\mathcal{P}(n)$, der endlichen Menge von Partitionen von $[n]$.
3. Eine zufällige Partition auf $\mathbb{N}$ ist eine Folge $\Pi = (\Pi_n)_{n \in \mathbb{N}}$ von Zufallsvariablen auf einem gemeinsamen Wahrscheinlichkeitsraum mit Werten in der endlichen Menge von Partitionen von $[n]$, sodass für $i < j, i, j \in \mathbb{N}$ die Restriktion von Π_j auf $[i]$ Π_i ist.

Definition 3. (Austauschbarkeit)

1. Eine zufällige Partition Π_n von $[n]$ heißt partiell Austauschbar, falls für jede Partition $\{A_1 \dots A_k\}$ von $[n]$ in Reihenfolge ihres Erscheinens¹

$$\mathbb{P}(\Pi_n = \{A_1 \dots A_k\}) = p(|A_1|, \dots, |A_k|)$$

für eine Funktion p von Kompositionen $\mathbf{n} := (n_1, \dots, n_k)$ von n gilt. Diese Funktion wird auch als PEPF (Partially Exchangeable Probability Function) bezeichnet.

2. Falls die Funktion p zusätzlich noch symmetrisch ist, so ist die zufällige Partition Π_n Austauschbar und man bezeichnet p als EPPF (Exchangeable Partition Probability Function).

Die Mengen A_i werden im weiteren Verlauf als Klassen bezeichnet.

Bemerkung 1. Dass bei einer symmetrischen Funktion p , die zufällige Partition tatsächlich Austauschbar ist, folgt aus der Definition und der Diskussion in [1, Seite 85]: eine Partition heißt austauschbar, falls

$$\mathcal{L}(\Pi_n) = \mathcal{L}(\pi(\Pi_n)),$$

für jede Permutation π von $\{1 \dots n\}$ gilt. Hier wirkt π auf Partitionen $(A_1, \dots, A_k)$ von n über $\pi(A_1, \dots, A_k) = (\pi(A_1), \dots, \pi(A_k))$ und $\pi(A_i) = \{\pi(i) | i \in A_i\}$.

Definition 4. Konsistenz

Wir nennen eine Folge von austauschbaren zufälligen Partitionen (Π_n) konsistent, falls die Restriktion $\Pi_{m,n}$ von Π_m zu $[n]$ für alle $m > n$ die gleiche Verteilung hat wie Π_m . Alle zufälligen Partitionen auf $\mathbb{N}$ sind konsistent.

Lemma 1.1. Sei Π_n eine partiell austauschbare zufällige Partition von $[n]$ mit PEPF $p(\mathbf{n})$ und Π_m die Restriktion von Π_n auf $[m]$, $m \in \{1 \dots n\}$. Dann gilt mit

$$\mathbf{m} := (m_1, \dots, m_k), \quad \sum_{i=1}^k m_i = m, \quad m_i \in \mathbb{N}$$

¹In Reihenfolge ihres Erscheinens bedeutet $1 \in A_1$, und für alle $2 \leq i \leq k$, das erste Element von $[n] \setminus \cup_{j=1}^{i-1} A_j$ zu A_i gehört

und

$$\mathbf{m}^{i+} = \mathbf{m} + e_i = \mathbf{m} + \underbrace{(0, \dots, 0 \underset{i-1 \text{ 0-en}}{1}, 0, \dots, 0)}_{k+1}, i \in \{1 \dots k+1\}$$

für Einheitsvektoren e_i :

$$\Pi_m \text{ ist partiell Austauschbar mit PEPPF } p(\mathbf{m}) := \sum_{j=1}^{k+1} p(\mathbf{m}^{j+}).$$

Beweis. Leichte Induktion, siehe [11, Proposition 10]. □

Bemerkung 2. Es wird sich später erweisen, dass wir für bestimmte Konstruktionen von austauschbaren Partitionen von $\mathbb{N}$ die *PEPPF* explizit nachprüfen sollen. Dafür ist folgendes Lemma nützlich.

Lemma 1.2. Sei N_m , $1 \leq m \leq n$ ein zufälliges Element in der Größe der Klassen einer Partition Π_n in Reihenfolge ihres Erscheinens. Falls $(N_1, \dots, N_n)$ eine Markov Kette ist mit

$$\mathbb{P}(N_{m+1} = \mathbf{n}^{i+} | N_m = \mathbf{n}) = \frac{p(\mathbf{n}^{i+})}{p(\mathbf{n})} \quad (1.1)$$

für ein $p : \bigcup_{i=1}^n \mathbb{N}^i \rightarrow [0, 1]$, $p(1) = 1$, dann ist Π_n partiell Austauschbar mit *PEPPF* p .

Beweis. Wir bemerken zuerst aus Definition 3, falls wir $N_n^* := \{\mathbf{n} := (n_1, \dots, n_k) | k \in \mathbb{N}, \sum_{i=1}^k n_i = n\}$ definieren, dass p eine *PEPPF* ist, falls $S_n := \sum_{\mathbf{n} \in N_n^*} \#(\mathbf{n})p(\mathbf{n}) = 1$ und $p(\mathbf{n}) \in [0, 1]$. Hier ist

$$\#(\mathbf{n}) := \frac{n!}{n_k(n_k + n_{k-1}) \dots (n_k + \dots + n_1) \prod_{i=1}^k (n_i - 1)!}, \quad (1.2)$$

die Anzahl der Partitionen von $[n]$ mit Klassengrößen in Reihenfolge ihres Erscheinens durch $\mathbf{n}$ gegeben (Siehe Bemerkung 3). Angenommen $S_n \neq 1$, dann gilt aber $S_n > 0$ und wir definieren $q(\mathbf{n}) := \frac{p(\mathbf{n})}{S_n}$. Dann ist $q(\mathbf{n})$ aus Lemma 1.1 zusammen mit 1.1 eine *PEPPF*, also $q(1) = \frac{p(1)}{S_n} = 1 \Rightarrow S_n = 1$, somit ist $p(\mathbf{n})$ eine *PEPPF* und die Behauptung ist gezeigt. □

Bemerkung 3. Das $\#(\mathbf{n})$ tatsächlich die Form 1.2 hat, wird im Anhang, Lemma 4.2, bewiesen und ist für die restliche Ausarbeitung nicht weiter relevant.

1.3 Kingman Paintbox representation

Oftmals ist es nützlich, die Menge $\{|A_1|, |A_2|, \dots, |A_k|\}$ der Größe der Blöcke einer Partition P_n von $[n]$ mit einer Folge von nicht negativen ganzen Zahlen zu identifizieren. Es gibt verschiedene Möglichkeiten dies zu machen [12, Seite 15]. Für unsere Zwecke reicht es einer dieser Repräsentationen zu betrachten.

Für eine Partition P_n definieren wir $|P_n|$ als die Anzahl der Blöcke und betrachten die absteigende Folge der Größen der Blöcke $(N_{n,1}^\downarrow, N_{n,2}^\downarrow, \dots, N_{n,|P_n|}^\downarrow, 0, 0, \dots)$. Wir fügen also nach dem kleinsten Block $N_{n,|P_n|}^\downarrow$, eine unendliche Folge von Nullen hinzu. Wir haben also eine

bijektive Identifizierung von der Menge der Partitionen von n zur folgenden Menge der Nichtnegativen natürlichen Zahlen:

$$\{(n_j)_{1 \leq j \leq \infty} : n_1 \geq n_2 \geq \dots \geq 0 \text{ und } \sum_{j=1}^{\infty} n_j = n\}.$$

Die Aussage, die wir in diesem Kapitel beweisen, bezieht sich auf die relative Größe der Blockgrößen, also betrachten wir die normierte Form dieser Menge und definieren:

$$\{(\frac{n_j}{n})_{1 \leq j \leq \infty} : \frac{n_1}{n} \geq \frac{n_2}{n} \geq \dots \geq 0 \text{ und } \sum_{j=1}^{\infty} \frac{n_j}{n} = 1\} \quad (1.3)$$

$$\subset \{(p_j^\downarrow)_{1 \leq j \leq \infty} : p_1^\downarrow \geq p_2^\downarrow \geq \dots \geq 0 \text{ und } \sum_{j=1}^{\infty} p_j^\downarrow = 1\} =: \nabla \quad (1.4)$$

Das Ziel ist es nun, eine ähnliche Aussage wie im Satz von de Finetti für Partitionen von $\mathbb{N}$ zu formulieren. Dazu starten wir mit dem Satz selbst.

Satz 1.3. [1, Theorem 3.1] *De Finetti*

Eine austauschbare Folge $(X_i)_{i \in \mathbb{N}}$ ist eine Mischung von i.i.d Folgen.

Bemerkung 4. Für die Zwecke dieser Arbeit reicht es eine Mischung von i.i.d Folgen, als „es existiert ein zufälliges W-Maß μ , sodass bedingt auf μ , die X_i i.i.d sind“, zu interpretieren. Auf die formale Definition verweisen wir auf [1, Abschnitt 1.2].

Bemerkung 5. Die Äquivalenz dieser Formulierung von de Finetti zu der Formulierung i.i.d gegeben einer σ -Algebra wird in [1, Lemma 2.18] bewiesen.

Kingman's Paintbox

Sei μ eine zufällige Verteilung mit Werten in $[0, 1]$ und $(X_i)_{i \in \mathbb{N}}$ eine Folge von unabhängig identisch verteilten Zufallsvariablen mit Verteilung μ . Sei $\Pi(\omega)$ die zufällige Partition mit Komponenten $\{i | X_i(\omega) = x\}, 0 \leq x \leq 1$. Die Bezeichnung von diesen austauschbaren² Prozess als *Paintbox Prozess* stammt aus der Vorstellung, dass man Objekte $\{1, 2, \dots\}$ mit Farben X_i markiert (Die Zahlen $x \in [0, 1]$ interpretiert man als Farben-Spektrum). Man erhält somit eine Partition von Mengen von gleichfarbigen Objekten. Die Verteilung der zufälligen Partition Π in dieser Konstruktion hängt nur von den Größen der Atome von μ ab ($\{x \in [0, 1] | \mu(x) > 0\}$). Wir definieren $p_j^\downarrow := \mu(x_j)$, sodass die x_j die Atome von μ sind und $p_j^\downarrow$ eine absteigende Folge ist. Die Aussage von *Kingman's representation* ist, dass bereits jede austauschbare Folge von $\mathbb{N}$ so konstruiert werden kann, also nur von der Folge $(p_i^\downarrow)_{i \in \mathbb{N}}$ abhängig ist. Um das Formal aufzufassen, definieren wir:

$$\begin{aligned} L : \mathcal{M}_1([0, 1]) &\rightarrow \nabla \\ \mu &\rightarrow (p_j^\downarrow)_{j \in \mathbb{N}}, \end{aligned}$$

und nennen den oben beschriebenen Prozess zur Verteilung μ den $L(\mu) = (p_j^\downarrow)_{j \in \mathbb{N}}$ -*Paintbox Prozess*. Der Satz besagt nun:

²Die Austauschbarkeit folgt aus Betrachtung von $\Pi_{i,j} := \{\omega | i \text{ und } j \text{ in derselben Komponente von } \Pi(\omega)\}$ und aus der Definition der Austauschbarkeit: Π ist austauschbar genau dann, wenn $\Pi_{i,j} \stackrel{\mathcal{L}}{=} \Pi_{\pi(i), \pi(j)}$ für alle Permutationen π_n auf $[n]$ gilt

Satz 1.4. Kingman's Representation

Sei $\Pi := (\Pi_n)_{n \in \mathbb{N}}$ eine austauschbare zufällige Partition von $\mathbb{N}$ und $(N_{n,i}^\downarrow, i \geq 1)$ die fallende Folge der Blockgrößen von Π_n , mit $N_{n,i}^\downarrow = 0$, falls Π_n weniger als i Blöcke hat.

Dann konvergiert $\frac{N_{n,i}^\downarrow}{n} \forall i \geq 1$ P-f.s. für $n \rightarrow \infty$ gegen ein (zufälliges) $P_i^\downarrow$. Weiter ist die bedingte Verteilung von Π_∞ gegeben $(P_i^\downarrow, i \geq 1)$ gleich der Verteilung von einem $(P_i^\downarrow, i \geq 1)$ Paintbox Prozess.

Beweis. Sei $(U_i)_{i \in \mathbb{N}}$ eine Folge unabhängig in $[0, 1]$ uniform verteilter Zufallsvariablen. Wir definieren

$$F_i(\omega) = \min \{j | i \text{ und } j \text{ sind in der gleichen Komponente von } \Pi(\omega)\} \leq i$$

$$Z_i = U_{F_i}.$$

$\Pi(\omega)$ ist also eine Partition mit Komponenten $\{i | Z_i(\omega) = z\}$ für $0 \leq z \leq 1$. $(Z_i)_{i \in \mathbb{N}}$ ist austauschbar, da wir $(Z_i)_{i \in \mathbb{N}} = g((\Pi_i)_{i \in \mathbb{N}}, (U_i)_{i \in \mathbb{N}})$ für eine Abbildung g auffassen können, und da Abbildungen austauschbarer Folgen austauschbar sind³. Nach De Finetti gibt es ein zufälliges Maß α , sodass bedingt auf $\alpha = \mu$, die Z_i unabhängig identisch wie μ verteilt sind. Dies entspricht aber genau dem vorher beschriebenen $L(\mu)$ -Paintbox Prozess und die zweite Behauptung ist gezeigt. Für die erste Behauptung nutzen wir das starke Gesetz großer Zahlen. Dafür sei ϕ ein beliebiges Maß mit $L(\phi) = (p_i^\downarrow)_{i \in \mathbb{N}}$ und X_i i.i.d ϕ verteilt. Dann gilt nach dem Gesetz $\frac{1}{n} \sum_{i=1}^n \chi_{\{X_i=x\}} \rightarrow \mathbb{P}(X_i=x) = \phi(x)$ P-f.s. für $n \rightarrow \infty$, somit konvergieren die normierten absteigenden Blockgrößen gegeben der Verteilung ϕ gegen $L(\phi) = (p_1, p_2, \dots)$ und die Behauptung ist gezeigt. $\square$

1.4 Chinese Restaurant Process

Der *Chinese Restaurant Process*, dient der Konstruktion von zufälligen austauschbaren Partitionen, mithilfe welcher die Analyse von Bäumen erleichtert wird. In Kapitel 2, wird eine Bijektion zwischen den Bäumen und Partitionen aufgestellt und dies erlaubt uns, die in diesem Kapitel entwickelte Theorie anzuwenden. Wir beginnen mit der Konstruktion vom „Chinese Restaurant Process“.

Konstruktion von CRP

Bevor die Konstruktion vom Prozess beschrieben wird, wollen wir vorab das Ziel der Konstruktion erläutern. Die Konstruktion erlaubt uns eine konsistente Folge von austauschbaren zufälligen Partitionen von $[n]$ zu erzeugen, also eine zufällige Partition Π_∞ von $\mathbb{N}$ zu generieren. Dies erlaubt uns u.a. Kingmans Sätze wie *Kingman's Correspondance* und *Kingman's representation* zu nutzen und somit Aussagen über die Grenzwerte der Größe der Blöcke von Partitionen zu formulieren. Wir beginnen mit einer einfachen Form des Prozesses:

Wir betrachten eine Folge von zufälligen Permutationen $\{\sigma_n, n \in \mathbb{N}\}$, sodass

1. $\{\sigma_n\}$ Uniform verteilt auf $[n]$ ist.

³Man beachte, dass hier die Folge U_i auch von Π unabhängig sein sollte.

2. $\forall n \in \mathbb{N}$, falls σ_n als Produkt von Zyklen dargestellt wird, σ_{n-1} von σ_n durch Deletion von Element n zurückgewonnen wird.

Die Verteilung, die durch diese zwei Regeln entsteht, kann durch einen zufälligen Sitzplan in einem chinesischen Restaurant beschrieben werden. Man stelle sich das Restaurant zunächst vor als eine Sammlung von abzählbar unendlichen vielen Tischen, wo jeder Tisch die Sitzplatzkapazität von abzählbar unendlich vielen Kunden hat. Die Kunden, nummeriert mit den natürlichen Zahlen nach Reihenfolge Ihres Erscheinens, werden nach folgenden Regeln platziert.

1. Der erste Kunde sitzt an Tisch 1
2. Falls zum Zeitpunkt des Eintritts des i -ten Kunden k Tische besetzt sind, so setzt sich dieser mit gleicher Wahrscheinlichkeit $(\frac{1}{n+1})$ links von Kunden $i : i \in \{1 \dots n\}$ oder an einem neuen Tisch $k + 1$.

Wir definieren nun $\sigma_n : [n] \rightarrow [n]$ mithilfe dieser Regeln, sodass falls Kunde i links von Kunde j sitzt, $\sigma_n(i) = j$ und falls Kunde i alleine sitzt $\sigma_n(i) = i$. Dass diese Folge von Permutationen die ersten 2 Regeln befolgt, ist durch eine triviale Induktion ersichtlich. Die Folge, die durch die Zyklen von den Permutationen generiert werden, ist austauschbar und konsistent, generiert somit eine austauschbare Folge Π_∞ von $\mathbb{N}$.

1.5 Verallgemeinerte CRP

Die einfache Konstruktion vom *Chinese Restaurant Process* lässt sich recht einfach verallgemeinern, sodass eine größere Klasse von austauschbaren Partitionen betrachtet werden können. Anstatt, wie im einfachen Fall, nur uniform ein Sitzplatz auszuwählen (Regel 2), wird in der allgemeinen Form des Prozesses eine beliebige Folge $(P_1, P_2 \dots)$ von Zufallsvariablen, mit $\sum_{i \geq 1} P_i \leq 1$ und $P_i \geq 0$ gewählt, und die zweite Regel mit folgender ersetzt:

- Falls zum Zeitpunkt des Eintritts des i -ten Kunden k Tische besetzt sind, so setzt sich dieser mit Wahrscheinlichkeit $P_j, j \in \{1 \dots k\}$ an Tisch j und mit Wahrscheinlichkeit $1 - \sum_{j=1}^k P_j$ an einen neuen Tisch.

Dieser Prozess erlaubt es nicht nur jede austauschbare Folge zu konstruieren, sondern tatsächlich jede partiell austauschbare Folge zu konstruieren. Beruhend auf dieser Konstruktion, hat Pitman [11] folgende Variation von *Kingman's Representation* bewiesen

Satz 1.5. *Sei Π_∞ eine zufällige Partition von $\mathbb{N}$, dann sind folgende Äquivalent*

1. Π_∞ ist partiell Austauschbar
2. Falls wir die Tische mit Partitionen identifizieren, dann wird Π_∞ gegeben $(P_1, P_2 \dots)$ durch den verallgemeinerten Chinese Restaurant Process generiert. Also $\forall n \in \mathbb{N}$ bedingt gegeben $(P_1, P_2 \dots)$ und $\Pi_n = \{A_1, A_2, \dots, A_k\}$, mit $A_i, i \in \{1 \dots k\}$ in Reihenfolge ihres Erscheinens, Π_{n+1} eine Erweiterung von Π_n ist, wobei $n+1$ zur Klasse A_i mit Wahrscheinlichkeit P_i angefügt wird und zur einer neuen Klasse A_{k+1} mit Wahrscheinlichkeit $1 - \sum_{i=1}^k P_i$ angefügt wird.

Weiter sind die P_i in 2. fast sicher eindeutig und gleich der fast sicheren asymptotischen Frequenz der Klassen A_i , also

$$\frac{|A_i \cap [n]|}{n} \rightarrow P_i \quad P\text{-f.s. für } n \rightarrow \infty.$$

Beweis. Dieser Satz wird in [11] bewiesen. □

Bemerkung 6. Der Vorteil von Pitmans Charakterisierung von partiell Austauschbaren Folgen gegenüber *Kingman's Representation* ist die Bestimmung der Verteilung $(P_1, P_2, \dots)$ im Vergleich zu der sortierten Folge $(P_1^\downarrow, P_2^\downarrow, \dots)$, welche durch die Konstruktion vom *Chinese Restaurant Process* erleichtert wird. Mithilfe vom Korollar 1.6 lässt sich die *PEPF*, bzw. *EPPF* im austauschbaren Fall, recht einfach berechnen.

Korollar 1.6. Die *PEPF* p von Satz 1.5 hat Form

$$p(n_1, n_2, \dots, n_k) = \mathbb{E} \left[\prod_{i=1}^k P_i^{n_i-1} \prod_{i=1}^{k-1} (1 - \sum_{j=1}^i P_j) \right]. \quad (1.5)$$

Beweis. Nach Definition 3, gilt mit $\mathbb{A}_n := \{A_1, \dots, A_k\}$ und $\mathbb{A}_{n-1} := \mathbb{A}_n \cap [n-1]$ und Satz 1.5

$$\begin{aligned} p(|A_1|, \dots, |A_k|) &= \mathbb{P}(\Pi_n = \mathbb{A}) \\ &= \mathbb{E} [\mathbb{P}(\Pi_n = \mathbb{A}_n | (P_1, P_2, \dots))] \\ &= \mathbb{E} [\mathbb{P}(\Pi_n = \mathbb{A}_n | \Pi_{n-1} = \mathbb{A}_{n-1}, (P_1, P_2, \dots)) \mathbb{P}(\Pi_{n-1} = \mathbb{A}_{n-1} | (P_1, P_2, \dots))] \\ &= \dots = \mathbb{E} \left[\prod_{i=1}^k P_i^{n_i-1} \prod_{i=1}^{k-1} (1 - \sum_{j=1}^i P_j) \right]. \end{aligned}$$

□

Mithilfe einer anderen Konstruktion von austauschbaren $\mathbb{N}$ [11, Konstruktion 16], stellt sich heraus, dass die P_i in Form von einer *Residual allocation Model (RAM)* sich darstellen lassen. Das bedeutet, dass unabhängige Zufallsvariablen $W_i, i \geq 1, W_i \in [0, 1]$ existieren, sodass die P_i aus Satz 1.5 als Produkt von den W_i

$$P_i = W_i \prod_{j=1}^{i-1} (1 - W_j) \quad (1.6)$$

sich darstellen lassen. Korollar 1.6 ändert sich somit zu

Korollar 1.7. Die *PEPF* p von Satz 1.5 hat Form

$$p(n_1, n_2, \dots, n_k) = \mathbb{E} \left[\prod_{i=1}^k W_i^{n_i-1} (1 - W_i)^{\sum_{j=i+1}^k n_j} \right].$$

Beweis. Wir nutzen 1.6 und Induktion um zuerst

$$\prod_{i=1}^n (1 - W_i) = 1 - \sum_{i=1}^n P_i$$

zu zeigen.

$n = 1$: klar.

Sei die Aussage für n Wahr, dann gilt

$$\begin{aligned} 1 - \sum_{i=1}^{n+1} P_i &\stackrel{I.A.}{=} \prod_{i=1}^n (1 - W_i) - P_{n+1} \\ &= \prod_{i=1}^n (1 - W_i) - W_{n+1} \prod_{i=1}^n (1 - W_i) \\ &= \prod_{i=1}^{n+1} (1 - W_i). \end{aligned}$$

Eingesetzt in 1.5, liefert

$$\begin{aligned} p(n_1, n_2, \dots, n_k) &= \mathbb{E} \left[\prod_{i=1}^k W_i^{n_i-1} \prod_{j=1}^{i-1} (1 - W_j)^{n_i-1} \prod_{i=1}^{k-1} \prod_{j=1}^i (1 - W_j) \right] \\ &= \mathbb{E} \left[\prod_{i=1}^k W_i^{n_i-1} \prod_{j=1}^{i-1} (1 - W_j)^{n_i-1} \prod_{i=1}^k \prod_{j=1}^{i-1} (1 - W_j) \right] \\ &= \mathbb{E} \left[\prod_{i=1}^k W_i^{n_i-1} \prod_{j=1}^{i-1} (1 - W_j)^{n_i} \right] \\ &= \mathbb{E} \left[\prod_{i=1}^k W_i^{n_i-1} (1 - W_i)^{\sum_{j=i+1}^k n_j} \right]. \end{aligned}$$

□

Wir nutzen die bis jetzt entwickelte Theorie der austauschbaren Partitionen, um eine Klasse von *Chinese Restaurant Process* zu betrachten, welche für spätere Baumanalyse von Relevanz sein wird. Dafür ersetzen wir die zweite Regel in der Konstruktion vom verallgemeinerten *Chinese Restaurant Process* mit genauen Wahrscheinlichkeiten. Für Parameter α und θ halten wir fest:

- Falls zum Zeitpunkt des Eintritts des i -ten Kunden k Tische mit jeweils $(n_1, \dots, n_k)$ Kunden besetzt sind, so setzt sich dieser mit Wahrscheinlichkeit $\frac{n_j - \alpha}{n + \theta}$ an Tisch $j \in \{1 \dots k\}$ und mit Wahrscheinlichkeit $\frac{\theta + k\alpha}{n + \theta}$ an einen neuen Tisch $k + 1$.

Damit die Wahrscheinlichkeitsregeln bei dieser Konstruktion erhalten bleiben, müssen α und θ entsprechend gewählt werden, dafür gibt es 2 Fälle (Siehe Anhang, Lemma 4.3):

1. $0 \leq \alpha < 1$ und $\theta > -\alpha$

2. $\alpha < 0$ und $\theta = -m\alpha$ für ein $m \in \mathbb{N}$

Das Haupttheorem ist nun folgendes.

Satz 1.8. *Für jede der Parameter (α, θ) , welche die oben genannten Voraussetzungen erfüllen, generiert der CRP eine austauschbare Partition von $\mathbb{N}$. Die dazu gehörende EPPF (siehe Def. 3) ist*

$$p_{\alpha, \theta}(n_1, \dots, n_k) = \frac{\prod_{i=0}^{k-2} (\theta + \alpha + i\alpha) \prod_{j=1}^k \prod_{r=1}^{n_j-1} (r - \alpha)}{\prod_{i=1}^{n-1} (\theta + i)}. \quad (1.7)$$

Die zugehörigen asymptotischen Frequenzen, in Reihenfolge ihres Erscheinens, können folgendermaßen repräsentiert werden.

$$(P_1, P_2, P_3 \dots) = (W_1, \bar{W}_1 W_2, \bar{W}_1 \bar{W}_2 W_3 \dots).$$

Wobei W_i unabhängig voneinander, nach $\beta(1 - \alpha, \theta + i\alpha)$ verteilt sind und $\bar{W}_i := 1 - W_i$.

Bevor wir zum Beweis kommen, definieren wir die β -Verteilung und nennen Eigenschaften.

Definition 5. *Eine Zufallsvariable X ist $\beta(a, b)$, mit $a, b > 0$ verteilt, falls X die Wahrscheinlichkeitsdichte*

$$f(x) = \begin{cases} \frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1}, & x \in [0, 1] \\ 0 & \text{sonst,} \end{cases}$$

mit

$$B(a, b) := \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}$$

besitzt. Hier bezeichnet Γ die Gamma Funktion, $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$.

Aus Korollar 1.7 werden oft nur die Momente von W_i zur Verfügung stehen, woraus die Verteilung abgeleitet werden soll. Für Zufallsvariablen mit beschränktem Träger ist die Verteilung durch die Momente festgelegt, [3, Theorem 30.1], insbesondere auch für die β -Verteilung.

Lemma 1.9. *Für $X \sim \beta(a, b)$, gilt*

$$\mathbb{E}[X^k] = \prod_{r=0}^{k-1} \frac{a+r}{a+b+r}.$$

Beweis. Die Momente werden über die Berechnung der momenterzeugenden Funktion von X in [7, Kapitel 25] bewiesen. $\square$

Insbesondere folgt für die Parameter aus Satz 1.8:

Korollar 1.10. Für $X \sim \beta(1 - \alpha, \theta + i\alpha)$, gilt:

$$\mathbb{E}[X^k] = \prod_{r=1}^k \frac{r - \alpha}{r + \theta + (i - 1)\alpha}.$$

Mit diesem Hilfsmittel können wir nun den Satz beweisen.

Beweis von Satz 1.8. Wir beginnen mit der Austauschbarkeit. Dafür prüfen wir zuerst, dass $p_{\alpha, \theta}$ tatsächlich unserer EPPF entspricht. Wir nutzen Lemma 1.2 und beachten, dass $p(1) = 1$. Weiter sind die Übergangswahrscheinlichkeiten von $p_{\alpha, \theta}$ genau die Übergangswahrscheinlichkeiten von N_m aus dem Lemma. Nach Definition 3 ist die *PEPF* p symmetrisch, also ist die Konstruktion austauschbar. Für die asymptotischen Frequenzen nutzen wir Lemma 1.7 und verfahren Induktiv um die W_i zu bestimmen. Wir beachten, dass die Momente von W_i eindeutig die W_i charakterisieren, da Sie nach Voraussetzung beschränkten Träger in $[0, 1]$ haben. Für W_1 sind die Momente nun:

$$\begin{aligned} p(i) = \mathbb{E}[W_1^{i-1}] &= \frac{\prod_{j=1}^{i-1} (j - \alpha)}{\prod_{j=1}^{i-1} (\theta + j)} \\ &= \prod_{j=1}^{i-1} \frac{(j - \alpha)}{(\theta + j)} \end{aligned}$$

und somit $W_1 \sim \beta(1 - \alpha, \theta + \alpha)$ nach Korollar 1.10. Wir machen eine Induktion über den Index i von W_i und nehmen an, dass $W_n \sim \beta(1 - \alpha, \theta + n\alpha)$. Für W_{n+1} rechnen wir

$$\begin{aligned} \frac{p(\underbrace{1, \dots, 1}_{n-1}, i+1)}{p(\underbrace{1, \dots, 1}_{n-1}, i+2)} &= \frac{\mathbb{E}[(1 - W_n)^{i+1}]}{\mathbb{E}[(W_n)^{i+1}]} \mathbb{E}[W_{n+1}^i] \\ &\Rightarrow \frac{\theta + n\alpha}{i + 1 - \alpha} = \prod_{r=0}^i \frac{\theta + n\alpha + r}{1 - \alpha + r} \mathbb{E}[W_{n+1}^i] \\ &\Rightarrow \frac{\theta + n\alpha}{i + 1 - \alpha} \prod_{r=1}^{i+1} \frac{r - \alpha}{r - 1 + \theta + n\alpha} = \mathbb{E}[W_{n+1}^i] \\ &\Rightarrow \prod_{r=2}^{i+1} \frac{1}{r - 1 + \theta + n\alpha} \prod_{r=1}^i r - \alpha = \mathbb{E}[W_{n+1}^i] \\ &\Rightarrow \prod_{r=1}^i \frac{r - \alpha}{r + \theta + n\alpha} = \mathbb{E}[W_{n+1}^i]. \end{aligned}$$

Die Aussage folgt. □

Definition 6. GEM und PD Verteilungen

Die Verteilung der $(P_1, P_2, \dots)$ aus Satz 1.8 wird nach Griffith-Engen-McCloskey für Parameter α, θ die $GEM(\alpha, \theta)$ -Verteilung genannt. Die dazugehörige Verteilung der nach der abfallenden-Größe sortierten $(P_i^\downarrow)_{i \in \mathbb{N}}$ wird mit *Poisson-Dirichlet* (α, θ) , bzw. $PD(\alpha, \theta)$ -Verteilung gekennzeichnet.

Linear preferential trees

In diesem Kapitel werden *general preferential trees* eingeführt und die Einbettung von diesen in Devroyes *Split* Bäume besprochen. Wir beginnen mit der Konstruktion von den jeweiligen Bäumen.

2.1 Konstruktion von general preferential trees

Der Aufbau von *general preferential attachment trees* folgt im Wesentlichen dem Aufbau von *random recursive Trees*. Wobei in *random recursive Trees* Knoten aufeinanderfolgend, mit uniformer Wahrscheinlichkeit als Kind von bereits existierenden Knoten angefügt werden, ist das Anknüpfen von Knoten von *general preferential attachment trees* noch abhängig vom Ausgangsgrad von den existierenden Knoten. Präziser formuliert, wird der Vaterknoten v von einem neuen Knoten, proportional zu $w_{d(v)}$ ausgesucht, wobei $d(v)$ der Ausgangsgrad vom Knoten v ist, und $w_1, w_2, \dots$ eine Folge von Gewichten ist. Der Fall $w_i = 1, \forall i \in \mathbb{N}$, führt somit genau auf den Fall von *random recursive trees* zurück. In dieser Ausarbeitung werden die Gewichte von der Form

$$w_k = \chi k + \rho, \chi \in \mathbb{R} \quad \rho > 0$$

betrachtet, woher der Name *linear preferential attachment trees* auch stammt. Da der Vaterknoten lediglich proportional zu der Folge von Gewichten ausgesucht wird, ändert die Skalierung der Folge nicht die Verteilung der Baumstruktur, und somit kann die Betrachtung von den Gewichten auf 3 Spezialfälle unterteilt werden:

1. $\chi = 1$ ist der Fall vom *general plane oriented recursive trees* [10]
2. $\chi = 0$ ist der Fall vom *random recursive trees*
3. $\chi = -1$ ist der Fall von *m-ary increasing trees*.

Bemerkung 7. Der Fall $\rho = -1$ kann, ohne zusätzliche Annahmen, zu negativen Gewichten führen. Die zusätzlichen Annahmen die gebraucht werden um dies zu vermeiden, sowie andere Eigenschaften von diesen Bäumen, werden im Kapitel *m-ary increasing trees* behandelt.

Satz 2.1. [6, Lemma 3.1] Mit den linearen Gewichten $w_k = \chi k + \rho$, hat ein preferential Baum T mit m Knoten ein Gesamtgewicht $w(T) = (m-1)\chi + m\rho = m(\chi + \rho) - \chi$.

Beweis. Seien $d_1 \dots d_m$ die Ausgangsgrade der jeweiligen Knoten im Baum. Dann ist die Summe der Ausgangsgrade, $\sum_{i=1}^m d_i = m - 1$ und somit:

$$w(T) = \sum_{i=1}^m w_i = \sum_{i=1}^m (\chi d_i + \rho) = m\rho + \chi \sum_{i=1}^m d_i = m(\chi + \rho) - \chi.$$

□

Definition 7. Falls T ein verwurzelter Baum ist, und v ein Knoten in T , so bezeichnen wir mit T^v den Teilbaum von T mit Wurzel v . Ein *principal Subtree* T^v von T ist ein Teilbaum wo v ein Kind von der Wurzel von T ist.

Satz 2.2. [6, Theorem 3.2] Sei $(T_n)_1^\infty = (T_n^{\chi, \rho})_1^\infty$ eine Folge von linear preferential attachment trees, mit den Kindern von der Wurzel in der Reihenfolge ihres Erscheinens beschriftet. Sei $N_j(n) := |T_n^j|$, die Größe des j -ten Principal subtree von T_n . Dann gilt

$$\forall j \geq 1 \quad \frac{N_j(n)}{n} \rightarrow P_j \text{ für } n \rightarrow \infty \text{ P-f.s..}$$

Wobei die Zufallsvariablen P_j Verteilung $GEM(\frac{\chi}{\chi+\rho}, \frac{\rho}{\chi+\rho})$ haben.

Beweis. Da wir im Allgemeinen $\chi + \rho > 0$ annehmen dürfen, und da die Multiplikation von allen w_k mit einer Konstante nicht den Baum ändert, können wir o.B.d.A $\chi + \rho = 1$ annehmen. Das Argument folgt nun durch Übersetzung von Principal subtree zu Zyklen in Permutationen und eine Bijektion zwischen linear preferential attachment trees und Permutationen. Wir beginnen mit der Bijektion.

Dafür beschriften wir die Knoten sukzessiv, beginnend mit der Wurzel als 0, nach der Reihenfolge vom Hinzufügen zum Baum (der i -ter Knoten der hinzugefügt wird, wird mit $i - 1$ beschriftet). Die Wurzel, die mit 0 beschriftet wird, wird identifiziert mit der leeren Permutation und der Zweite Knoten, welcher mit 1 beschriftet wird, wird mit dem Zyklus (1) identifiziert. Wir identifizieren nun unsere Bäume mit Permutationen induktiv, nach folgenden zwei Regeln:

1. Falls der Knoten mit Beschriftung i an die Wurzel angehängt wird, so fügen wir zur bestehenden Zyklus-Dekomposition, die Fixpunkt-Permutation (i) hinzu.
2. Falls der Knoten mit Beschriftung i an einen anderen Knoten mit Beschriftung j , $j \neq 0$ angehängt wird, so fügen wir in den Zyklus C , welcher j enthält, i direkt nach j hinzu. Bedeutet also, falls im ursprünglichen Zyklus $j \rightarrow k$ abgebildet wurde, im nächsten Schritt $j \rightarrow i \rightarrow k$ abgebildet wird.

Es ist einfach zu zeigen, dass diese Abbildung von Bäumen zu Permutation, welche durch diese Konstruktion entsteht, bijektiv ist und somit können wir die Theorie der *austauschbaren Partitionen* anwenden, insbesondere also Satz 1.8. Dafür betrachten wir die bedingten Wahrscheinlichkeiten, dass der $n + 1$ -Knoten an principal Subtree i angefügt wird, gegeben er enthält bereits n_i Knoten. Nach Lemma 2.1, hat dieser Teilbaum Gesamtgewicht $n_i(\chi + \rho) - \chi = n_i - \chi$ und der gesamte Baum Gewicht $m - \chi$. Die bedingten Wahrscheinlichkeiten entsprechen also denen in der Konstruktion von einem (χ, ρ) *Chinese Restaurant Process* und die Aussage folgt direkt aus Satz 1.8. □

Bemerkung 8. Satz 2.2 wird eine zentrale Rolle bei der Bestimmung des *Split Vektors* in der Einbettung von *linear preferential attachment trees* in Devroyes Split Bäume spielen. Wir führen zuerst den Begriff und die Konstruktion der Split Bäume ein und kommen dann schließlich zu dieser Einbettung.

2.2 Konstruktion von Split Bäumen

Sei $b \geq 2$ fest und $\mathcal{P} = (P_i)_{1 \leq i \leq b}$ ein zufälliger Wahrscheinlichkeitsvektor, also $P_i \geq 0$ und $\sum_{i=1}^b P_i = 1$. Sei $\mathcal{T}_b$ der unendliche Wurzelbaum, in dem jeder Knoten b Kinder hat, beschriftet mit $1, \dots, b$. Wir geben jedem Knoten $v \in \mathcal{T}_b$ eine unabhängige Kopie von $\mathcal{P}$, die mit $\mathcal{P}^{(v)}$ bezeichnet wird. Jeder Knoten $v \in \mathcal{T}_b$ kann maximal einen Knoten enthalten und falls dieser einen enthält, so nennen wir den Knoten *voll*. Anfangs sind die Knoten leer und Bälle, beginnend mit der Wurzel, befüllen die Knoten nach folgenden zwei Regeln.

1. Ein Ball, der an einem leeren Knoten ankommt, bleibt dort. Dieser Knoten ist dann *voll*.
2. Ein Ball, der an einem *vollen* Knoten v ankommt, bewegt sich weiter an die Kinder von v . Das Kind wird zufällig ausgewählt, wobei Kind i mit Wahrscheinlichkeit $P_i^{(v)}$ ausgesucht wird.

Der zufällige Split Baum $T_n = T_n^{\mathcal{P}}$ ist nun der Baum der entsteht, wenn nur die Knoten betrachtet werden, welche die ersten n Bälle enthalten.

Bemerkung 9. Die hier vorggeführte Konstruktion ist nur eine Teilmenge von der allgemeineren Struktur von Devroyes Split Bäumen. In der Notation von Devroye [4], ist diese Teilmenge durch die Parameter $(s_0, s_1, s) = (1, 0, 1)$ festgelegt. Im weiteren Verlauf ist bei Bezugnahmen auf Split-Bäume stets dieser Spezialfall gemeint.

Mit dieser Vorarbeit können wir nun die *linear preferential attachment trees* in die Split Bäume einbetten, indem wir auch Split Bäume mit $b = \infty$ zulassen.

Satz 2.3. Seien (χ, ρ) Parameter, welche die Voraussetzungen vom Chinese Restaurant Process erfüllen und $\chi + \rho > 0$. Dann, falls die Bäume als ungeordnete Bäume betrachtet werden, hat der linear preferential attachment tree $T_n^{\chi, \rho}$ für alle $n \in \mathbb{N}$ die selbe Verteilung wie der zufällige Split Baum $T_n^{\mathcal{P}}$ mit $b = \infty$ und

$$\mathcal{P} \sim PD\left(\frac{\chi}{\chi + \rho}, \frac{\rho}{\chi + \rho}\right)$$

Beweis. Die Hauptidee hinter der Beweis liegt darin, die Konstruktion der *linear preferential attachment trees* in einer rekursiven Form aufzufassen und dann die Verteilung vom *Split Vektor* $\mathcal{P}$ mithilfe von Satz 1.8 zu bestimmen.

Nach Konstruktion der *linear preferential attachment trees* wird ein neuer Knoten an einen bestehenden Knoten u proportional zum Gewicht vom Knoten $w_{d(u)}$ angehängt. Die Wahrscheinlichkeit, dass ein Knoten an eine bestehende Gruppe von Knoten angehängt wird, ist daher proportional zur Summe der Gewichte dieser Gruppe. Dies erlaubt uns den Aufbau vom Baum rekursiv zu beschreiben. Dafür formulieren wir die Konstruktion vom *linear preferential attachment tree* nach folgenden Regeln um.

1. Ein Ball, der an einem leeren Knoten ankommt, bleibt dort. Dieser Knoten ist dann *voll*.
2. Ein Ball, der an einem *vollen* Knoten v ankommt, bewegt sich weiter an die Kinder von v . Falls Knoten v d Kinder $v_1, v_2, \dots, v_d$ hat, so bewegt sich dieser an Kind i mit Wahrscheinlichkeit $w(T^{v_i})/w(T^v)$ für alle $i \in \{1, \dots, d\}$ und an ein neues Kind $d+1$ mit Wahrscheinlichkeit $(\chi d + \rho)/w(T^v)$.

Wir beschriften die Bälle nach der Reihenfolge ihres Erscheinens beginnend mit der Wurzel als 0 (d.h. der $i+1$ -te Ball der zum Baum hinzugefügt wird, hat Beschriftung i). Seien weiter die Anzahl der Bälle im j -ten *principal Subtree* von T_n mit n_j bezeichnet. Nach Satz 2.1 können wir die Wahrscheinlichkeiten von der zweiten Regel berechnen.

$$\frac{w(T^{v_i})}{w(T^v)} = \frac{n_i(\chi + \rho) - \chi}{n(\chi + \rho) - \chi} = \frac{n_i - \chi}{n + \rho} \quad (2.1)$$

$$\frac{\chi d + \rho}{w(T^v)} = \frac{\chi d + \rho}{n + \rho}. \quad (2.2)$$

Wobei hier, Analog zu Satz 2.2, $\chi + \rho = 1$ angenommen wurde. Falls man die *Principal Subtrees* nun mit Tischen identifiziert, so sieht man direkt anhand 2.1 und 2.2, dass diese 2 Regeln von der Wurzel aus gesehen einen (χ, ρ) -*Chinese Restaurant Process* widerspiegeln.

Andererseits, besagt Satz 1.4, dass jede austauschbare zufällige Partition die gleiche Verteilung hat, wie ein $(P_i^\downarrow)_{i \in \mathbb{N}}$ -*Paintbox Prozess*, wobei $P_i^\downarrow$ der P-f.s. Grenzwert von der normierten i -ten Blockgröße von der Partition ist. Da in unserem Fall die Blockgrößen die Größen der *principal subtrees* sind, können auch Split-Bäume mithilfe der Theorie der austauschbaren Partionen dargestellt werden. Dafür betrachten wir die Verteilung der Bälle in die *principal Subtrees* nachdem die Wurzel mit einem Ball besetzt ist. Diese Verteilung ist Äquivalent zu einem $\mathcal{P}^v = (P_i^\downarrow)_{i \in \mathbb{N}}$ -Paintbox Prozess, falls man die Kinder der Knoten in einen Split Baum nach Reihenfolge ihres Erscheinens umbenennt. Nach Definition 6 und Satz 1.8 ist $(P_i^\downarrow)_{i \in \mathbb{N}} \sim PD(\chi, \rho)$ und die Behauptung ist gezeigt. $\square$

Bemerkung 10. In dieser Abwandlung der Konstruktion vom Split Baum kann der *Split Vektor* beliebig permutiert werden, da die Knoten in Reihenfolge ihres Erscheinens neu benannt wurden. Das bedeutet, dass der Satz für jede Permutation von einer $PD(\chi, \rho)$ Verteilung auch gilt, insbesondere also auch für die $GEM(\chi, \rho)$ Verteilung (Siehe Definition 6).

In Devroyes Publikation [4] spielt die Größen-verzerzte Version W von $\mathcal{P}$ eine wichtige Rolle. Die Verteilung ist durch folgendes Sampling festgelegt.

1. Gegeben $\mathcal{P} = (P_i)_{i \in \mathbb{N}}$, sei I eine Zufallsvariable welche durch Verteilung $P(I = i) = P_i, \forall i \in \mathbb{N}$ definiert ist.
2. $W := P_I$

oder in einer anderen Schreibweise

$$P(W = P_i | (P_i)_{i \in \mathbb{N}}) = P_i.$$

In unserem Fall ist die explizite Berechnung der Verteilung von W recht einfach.

Satz 2.4. Für den zufälligen Split Baum aus Satz 2.3, ist $W \sim \beta(\rho, 1)$.

Beweis. Wir nutzen die Einbettung von *linear preferential attachment trees* in die Split Bäume. Sei I die Zufallsvariable welche die Beschriftung vom ersten erschienen Knoten übernimmt (bevor die Knoten umbenannt werden). Nach Voraussetzung, gilt

$$P(I = i | (P_i)_{i \in \mathbb{N}}) = P_i.$$

Sei weiter S_n die Anzahl der Knoten im ersten *principal Subtree*. Bedingt auf $I = i$, gilt nach dem Gesetz der großen Zahlen, dass

$$\frac{S_n}{n} \rightarrow P_i \quad P - \text{f.s. für } n \rightarrow \infty.$$

Daher folgt $\frac{S_n}{n} \rightarrow P_I = W$ P-f.s. für $n \rightarrow \infty$.

Durch die Einbettung, kennen wir aber die relative Größe vom ersten *principal Subtree* welcher durch Satz 1.8 durch $P_1 = W_1 \sim \beta(1 - \chi, \chi + \rho) = \beta(\chi, 1)$ gegeben ist. Es folgt, dass $W \sim \beta(\chi, 1)$ und die Behauptung ist gezeigt. $\square$

Anwendungen

Dieses Kapitel nutzt die Hauptresultate aus dem vorherigen Kapitel um Aussagen über eine Funktion der Tiefe von Knoten in einem Baum für Split Bäume, als auch für *Linear preferential trees* zu beweisen.

Definition 8. Für einen gewurzelten Baum T , sei $h(v)$ die Tiefe eines Knotens v und sei $v \wedge w$ der letzte gemeinsame Vorfahr von v und w . Dann definieren wir die Funktion Y als:

$$Y := Y(T) = \sum_{v \neq w} h(v \wedge w),$$

wobei wir die Summe über geordnete Paare (v, w) definieren. Die Summe über geordnete Paare ist durch Symmetrie von $v \wedge w$ gleich dem doppelten der Summe über ungeordnete Paare.

Satz 3.1. Hoeffdings Gesetz großer Zahlen für U-Statistiken

Seien X_i i.i.d Zufallsvariablen, $f(X_1, \dots, X_r)$ eine Funktion mit Erwartungswert θ und sei $\tilde{f}_n$ definiert durch

$$\frac{1}{(n)_k} \sum_{\substack{i_1, \dots, i_k \in \{1 \dots n\} \\ \text{paarweise verschieden}}} f(X_{i_1}, \dots, X_{i_k}),$$

wobei $(n)_k := \prod_{i=0}^{k-1} (n - i)$. Dann konvergiert

$$\tilde{f}_n \rightarrow \theta \text{ P-f.s. für } n \rightarrow \infty.$$

Beweis. Das Gesetz wird in [5] bewiesen. □

Satz 3.2. Sei $(T_n^{\mathcal{P}})$ ein zufälliger Split Baum für einen Split Vektor $\mathcal{P} = (P_i)_{i \in \mathbb{N}}$ und sei $Y_n := Y(T_n^{\mathcal{P}})$ definiert wie in Definition 8. Wir nehmen an, dass für ein $i \in \mathbb{N}$, $0 < P_i < 1$ mit positiver Wahrscheinlichkeit. Dann existiert eine Zufallsvariable Q , sodass $Y_n/n^2 \rightarrow Q$ P-f.s. für $n \rightarrow \infty$. Weiter gilt

$$\mathbb{E}[Q] = \frac{1}{1 - \mathbb{E}[\sum_{i \geq 1} P_i]} - 1 < \infty. \quad (3.1)$$

Zusätzlich gilt, mit W so definiert wie nach Bemerkung 10, dass

$$\mathbb{E}[Q] = \frac{\mathbb{E}[W]}{1 - \mathbb{E}[W]}. \quad (3.2)$$

Beweis. Wir beginnen mit einer Approximation von Y_n für Split Bäume. Dafür modifizieren wir die Konstruktion von Split Bäumen und nehmen an, dass Anfangs bereits jeder Knoten *voll* ist. Bedeutet, dass bereits der erste Knoten nicht an der Wurzel hängen bleibt, sondern sich anhand der jeweiligen *Split Vektoren* der Knoten unendlich Tief entlang des Baums bewegt. Wir notieren den Pfad vom k -ten Ball, der sich so entlang des Baumes bewegt mit $\mathbf{X}_k = (X_{k,i})_{i \in \mathbb{N}}$, wobei $X_{k,i} \in \mathbb{N}$ die Knotenbeschriftung vom Pfad in der Tiefe i bezeichnet. Gegeben *Split Vektoren* $\mathcal{P}^v$ von allen Knoten v , sind die $\mathbf{X}_i$ i.i.d. durch die Verteilung

$$\mathbb{P}\left(\bigcap_{j=1}^m X_{k,j} = i_j\right) = \prod_{j=1}^m P_{i_j}^{(i_1 \dots i_{j-1})} \quad (3.3)$$

festgelegt, wobei wir mit $(i_1 \dots i_{j-1})$ den Knoten in der $(j-1)$ -ten Tiefe vom Pfad identifizieren. Sei nun für 2 Sequenzen $\mathbf{X}^1, \mathbf{X}^2 \in \mathbb{N}^\infty$ die Funktion f folgendermaßen definiert:

$$f(\mathbf{X}^1, \mathbf{X}^2) = \min(\{i : \mathbf{X}_i^1 \neq \mathbf{X}_i^2\}) - 1,$$

also die Länge der längsten gemeinsamen Anfangssequenz. Dann ist

$$f(\mathbf{X}^k, \mathbf{X}^l) = h(v_k, v_l),$$

falls beide gegenseitig kein Vorfahren vom anderen sind und $\mathbf{X}^k$ bzw. $\mathbf{X}^l$ die zugehörige Sequenz vom Knoten v_k bzw. v_l ist. In dem Falle das v_l ein Vorfahren von v_k ist, gilt

$$f(\mathbf{X}^k, \mathbf{X}^l) \geq h(v_k, v_l). \quad (3.4)$$

Mithilfe dieser Definition definieren wir unsere Approximation durch

$$\tilde{Y}_n = 2 \sum_{l < k \leq n} f(\mathbf{X}^k, \mathbf{X}^l).$$

Bedingt auf alle *Split Vektoren* $\mathcal{P}^v$, bekommen wir mit χ definiert als Indikator Funktion.

$$\begin{aligned} \mathbb{E}[f(\mathbf{X}^1, \mathbf{X}^2) | \{\mathcal{P}^v, v \text{ Knoten}\}] &= \sum_{m=1}^{\infty} \mathbb{P}(f(\mathbf{X}^1, \mathbf{X}^2) \geq m | \{\mathcal{P}^v, v \text{ Knoten}\}) \\ &= \sum_{m=1}^{\infty} \mathbb{P}\left(\bigcap_{j=1}^m \mathbf{X}_{1,j} = \mathbf{X}_{2,j}\right) \\ &= \sum_{m=1}^{\infty} \mathbb{P}\left(\bigcup_{i_1, \dots, i_m \in \mathbb{N}} \left\{\bigcap_{j=1}^m \mathbf{X}_{1,j} = \mathbf{X}_{2,j} = i_j\right\}\right) \\ &= \sum_{m=1}^{\infty} \sum_{i_1, \dots, i_m \in \mathbb{N}} \mathbb{P}\left(\left\{\bigcap_{j=1}^m \mathbf{X}_{1,j} = \mathbf{X}_{2,j} = i_j\right\}\right) \\ &= \sum_{m=1}^{\infty} \sum_{i_1, \dots, i_m \in \mathbb{N}} \mathbb{P}\left(\bigcap_{j=1}^m \mathbf{X}_{1,j} = i_j\right) \mathbb{P}\left(\bigcap_{j=1}^m \mathbf{X}_{2,j} = i_j\right) \\ &= \sum_{m=1}^{\infty} \sum_{i_1, \dots, i_m \in \mathbb{N}} \left(\prod_{j=1}^m P_{i_j}^{(i_1 \dots i_{j-1})}\right)^2 =: Q. \end{aligned} \quad (3.5)$$

Mit der Turmeigenschaft zusammen mit der Voraussetzung, dass die $P^{(v)}$ i.i.d sind, folgt

$$\begin{aligned}\mathbb{E}[f(\mathbf{X}^1, \mathbf{X}^2)] &= \mathbb{E}[Q] = \sum_{m=1}^{\infty} \sum_{i_1, \dots, i_m \in \mathbb{N}} \prod_{j=1}^m \mathbb{E}[P_{i_j}^2] \\ &= \sum_{m=1}^{\infty} \left(\sum_{i=1}^{\infty} \mathbb{E}[P_i^2] \right)^m \\ &= \frac{1}{1 - \sum_{i=1}^{\infty} \mathbb{E}[P_i^2]} - 1 = \frac{\sum_{i=1}^{\infty} \mathbb{E}[P_i^2]}{1 - \sum_{i=1}^{\infty} \mathbb{E}[P_i^2]}.\end{aligned}$$

Wobei wir in die letzte Gleichung die Summenformel für eine geometrische Reihe ausgenutzt haben, da $\sum_{i=1}^{\infty} P_i^2 \leq \sum_{i=1}^{\infty} P_i = 1$ mit positiver Wahrscheinlichkeit, $\sum_{i=1}^{\infty} \mathbb{E}[P_i^2] < 1$ impliziert. Die zweite Behauptung des Satzes (3.1) ist somit gezeigt. Für die letzte Behauptung 3.2, nutzen wir

$$P(W = P_i | (P_i)_{i \in \mathbb{N}}) = P_i.$$

und folgern

$$\mathbb{E}[W] = \mathbb{E}[\mathbb{E}[W | (P_i)_{i \in \mathbb{N}}]] \quad (3.6)$$

$$= \mathbb{E}\left[\sum_{i=1}^{\infty} P_i \mathbb{P}(W = P_i | (P_i)_{i \in \mathbb{N}})\right] \quad (3.7)$$

$$= \mathbb{E}\left[\sum_{i=1}^{\infty} P_i^2\right]. \quad (3.8)$$

Nach Hoeffdings Gesetz der großen Zahlen (Satz 3.1), gilt

$$\frac{\tilde{Y}_n}{n(n-1)} \rightarrow Q \text{ P-f.s. für } n \rightarrow \infty.$$

Es fehlt zu zeigen, dass $(\tilde{Y}_n - Y_n)/n^2 \rightarrow 0$ P-f.s. für $n \rightarrow \infty$.

Sei

$$H_n := \max\{h(v) : v \in T_n\} \quad (3.9)$$

die Höhe von $T_n := T_n^{\mathcal{P}}$ und

$$H_n^* := \max\{f(\mathbf{X}_k, \mathbf{X}_l) : l < k \leq n\}. \quad (3.10)$$

Wir definieren $v \prec w$, falls v ein Vorfahren von w ist. Dann gilt durch 3.4

$$\begin{aligned}0 \leq \tilde{Y}_n - Y_n &= 2 \sum_{k=1}^n \sum_{v_l \prec v_k} (f(\mathbf{X}_k, \mathbf{X}_l) - h(v_k \wedge v_l)) \\ &\leq 2 \sum_{k=1}^n \sum_{v_l \prec v_k} f(\mathbf{X}_k, \mathbf{X}_l) \\ &\leq 2 \sum_{k=1}^n \sum_{v_l \prec v_k} H_n^*\end{aligned}$$

$$\leq 2 \sum_{k=1}^n H_n H_n^* = 2n H_n H_n^* \quad (3.11)$$

wobei die letzte Ungleichung Wahr ist, da ein Knoten höchstens H_n Vorfahren hat. Nun hat der tiefst-liegende Knoten k die Tiefe H_n und falls der Vaterknoten mit l bezeichnet wird, so gilt

$$H_n^* \geq f(\mathbf{X}^k, \mathbf{X}^l) \geq H_n - 1. \quad (3.12)$$

Sei $m := m_n := \lceil c \log(n) \rceil$. Dann gilt, wie in der Gleichungskette 3.5,

$$\begin{aligned} \mathbb{P}(f(\mathbf{X}^1, \mathbf{X}^2) \geq m | \{\mathcal{P}^v, v \text{ Knoten}\}) &= \sum_{i_1, \dots, i_m \in \mathbb{N}} \mathbb{P}(\{\bigcap_{j=1}^m \mathbf{X}_{1,j} = \mathbf{X}_{2,j} = i_j\}) \\ &= \sum_{i_1, \dots, i_m \in \mathbb{N}} \left(\prod_{j=1}^m P_{i_j}^{(i_1, \dots, i_{j-1})} \right)^2. \end{aligned}$$

Und somit

$$\mathbb{P}(f(\mathbf{X}^1, \mathbf{X}^2) \geq m) = \sum_{i_1, \dots, i_m \in \mathbb{N}} \prod_{j=1}^m \mathbb{E}[P_{i_j}^2] =: a^m,$$

für $a := \sum_{i=1}^{\infty} \mathbb{E}[P_i^2] < 1$. Wir können jetzt H_n^* abschätzen. Dafür wählen wir $c \geq 4/|\log a|$ und rechnen

$$\begin{aligned} \mathbb{P}(H_n^* \geq m) &\leq \sum_{l < k \leq n} \mathbb{P}(f(\mathbf{X}_k, \mathbf{X}_l) \geq m) = \binom{n}{2} \mathbb{P}(f(\mathbf{X}_k, \mathbf{X}_l) \geq m) \\ &\leq n^2 \mathbb{P}(f(\mathbf{X}_k, \mathbf{X}_l) \geq m) \leq n^2 a^m \leq n^2 a^{c \log n} \leq n^{-2}. \end{aligned}$$

Da $\sum_{n \geq 1} \frac{1}{n^2} < \infty$, folgt mit Borel-Cantelli $H_n \leq c \log n$ P-f.s. für $n \rightarrow \infty$. Nun gilt mit 3.12 und 3.11, dass $(\tilde{Y}_n - Y_n) \in O(n \log^2(n))$ und somit ist die Behauptung $(\tilde{Y}_n - Y_n)/n^2 \rightarrow 0$ P-f.s. gezeigt. $\square$

Korollar 3.3. *Für ein linear preferential attachment tree mit Parametern (χ, ρ) mit $\chi + \rho > 0$ existiert eine Zufallsvariable Q , sodass $Y(T_n^{\chi, \rho})/n^2 \rightarrow Q$ P-f.s. Weiter hat Q den Erwartungswert*

$$\mathbb{E}[Q] = \rho.$$

Beweis. Das Q existiert folgt direkt aus Satz 3.2. Nach Satz 2.4, ist $W \sim \beta(\rho, 1)$ und hat somit Erwartungswert $\frac{\rho}{\rho+1}$. Satz 3.2 liefert nun

$$\mathbb{E}[Q] = \frac{\mathbb{E}[W]}{1 - \mathbb{E}[W]} = \frac{\frac{\rho}{\rho+1}}{\frac{1}{\rho+1}} = \rho$$

$\square$

m-ary increasing trees

In diesem Kapitel werden die Teilmenge der *linear preferential attachment trees*, mit Parametern der Form $\chi < 0$ und $\rho > 0$ näher betrachtet. Wie schon im ersten Kapitel bemerkt, ändert die Normierung von allen Gewichten w_k mit einer Konstante $c \in \mathbb{R}$ nicht die Verteilung der Bäume. Infolgedessen, betrachten wir $\chi = -1$ und prüfen, bei welchen $\rho \in \mathbb{R}^+$ es zu negative Gewichten kommt.

Für $\chi = -1$ sind die Gewichte der *linear preferential trees* durch

$$w_k = \chi k + \rho = \rho - k$$

festgelegt. Für $k > \rho$ folgt daraus, dass $w_k < 0$. Daher ist die einzige Möglichkeit negative Gewichte zu vermeiden, $w_m = 0$, für ein $m \in \mathbb{N}$ sicherzustellen. In diesem Fall kann einem Knoten mit m Kindern kein weiterer Knoten hinzugefügt werden, und die weiteren Gewichte $w_n, n > m$ sind von keiner Relevanz. Auf ρ bezogen, heißt das, dass $\rho = m \in \mathbb{N}$, falls $\chi = -1$, bzw. $\rho = m\chi, m \in \mathbb{N}$, falls wir χ nicht zu -1 normieren.

Bis jetzt wurden Bäume nur in einer ungeordneten Weise betrachtet, d.h. es zählte nur welche Geschwister ein Knoten hat, und nicht die Reihenfolge der Geschwister. Da in dieser Teilmenge der *linear preferential attachment trees* die Anzahl der Kinder pro Knoten durch m beschränkt ist, können wir die Bäume auch in einer geordneten Weise interpretieren. Das Beispiel $T_n^{-1,2}$ illustriert wie wir diesen Gedanken nachverfolgen können.

Beispiel. Die Gewichte von einem Knoten v in einem $T_n^{-1,2}$ haben die Form:

$$w_k = 2 - k, k \in \{0, 1, 2\},$$

wobei k der Ausgangsgrad von v ist. Wir können die Gewichte umschreiben, indem wir die Gewichte proportional zu den externen Kindern von v auffassen. Es gibt $e = m - k = 2 - k$ externe Kinder e von einem Knoten v und somit haben die Gewichte die Form

$$w_k = 2 - k = 2 - (2 - e) = e, e \in \{0, 1, 2\}.$$

Das bedeutet jeder Knoten hat Gewicht direkt proportional zu der Anzahl der externen Knoten. Diese Eigenschaft erlaubt uns den Aufbau von $T_n^{-1,2}$ geordnet zu interpretieren. Dazu beginne man mit einem vollständigen unendlichen 2-ären Baum, mit Kindern von einem Knoten mit $\{1, 2\}$ beschriftet und dann zufällig Uniform permutiert. Wir konstruieren dann den $(T_n^{-1,2})_{n \in \mathbb{N}}$ innerhalb von diesem $\mathcal{T}_2$ Baum: in jedem Schritt wird ein externer Knoten von $T_n^{-1,2}$ mit Beschriftung aus $\mathcal{T}_2$ uniform ausgewählt und hinzugefügt (Siehe Abbildung 4.1)




Abbildung 4.1: Beispiel für eine Konstruktion von einem $T_n^{-1,2}$ Baum. Die externen Knoten sind mit gestrichelter Linien abgebildet und W ist die Wurzel

Die geordnete Interpretation von $T_n^{-1,2}$ entspricht daher einem zufälligen Binärsuchbaum. Diese sind aber einer der elementaren Beispiele von Split Bäumen behandelt in [4], welche durch den Split Vektor $\mathcal{P} = (U, 1 - U)$ und $U \sim \text{Uniform}[0, 1]$ charakterisiert ist. Dies steht nicht in Widerspruch zu Satz 2.3, denn obwohl die Bäume $T_n^{-1,2}$ und $T_n^{(U, 1-U)}$ in der ungeordneten Interpretation dieselbe Verteilung haben, ist die Verteilung von $T_n^{\mathcal{P}}$ nicht eindeutig durch $\mathcal{P}$ festgelegt. Der Split Vektor $\mathcal{P}$ ist nach Bemerkung 10 nur bis auf (zufällige) Permutationen eindeutig, bedeutet es muss eine (zufällige) Permutation von $\mathcal{P}^1 := (P_1, 1 - P_1) \sim GEM(-1, 2)$ geben, sodass $\mathcal{P}^1 \stackrel{L}{=} \mathcal{P}^2 := (U, 1 - U)$. Nach Satz 1.8 ist $P_1 \sim \beta(1, 2)$ und hat somit nach Definition 5 Wahrscheinlichkeitsdichte $2x$ und $1 - P_1$ hat Dichte $2 - 2x$. Falls wir annehmen, dass die Permutation unabhängig von $(P_1, 1 - P_1)$ ist, so kann man der Permutation Wahrscheinlichkeiten zuordnen, sodass $(P_1, 1 - P_1)$ mit Wahrscheinlichkeit p_1 und $(1 - P_1, P_1)$ mit Wahrscheinlichkeit p_2 gewählt wird. Wir versuchen dann p_1, p_2 zu bestimmen, sodass wir die Verteilung $(U, 1 - U)$ zurückgewinnen. Wir definieren unsere zufällige Permutation mit $(\tilde{P}_1, \tilde{P}_2)$ und berechnen für $a \in [0, 1]$

$$\begin{aligned}
\mathbb{P}(\tilde{P}_1 \leq a) &= \mathbb{P}(P_1 \leq a | \tilde{P}_1 = P_1) \mathbb{P}(\tilde{P}_1 = P_1) + \mathbb{P}(P_1 \leq a | \tilde{P}_1 = P_2) \mathbb{P}(\tilde{P}_1 = P_2) \\
&= \mathbb{P}(P_1 \leq a | \tilde{P}_1 = P_1) p_1 + \mathbb{P}(P_1 \leq a | \tilde{P}_1 = P_2) p_2 \\
&= \int_0^a p_1 2x dx + \int_0^a p_2 (2 - 2x) dx \\
&= \int_0^a p_1 2x + p_2 (2 - 2x) dx.
\end{aligned}$$

Somit hat $\tilde{P}$ Wahrscheinlichkeitsdichte $p_1 2x + p_2 (2 - 2x)$. U hat nach Voraussetzung Wahrscheinlichkeitsdichte 1 und mit einem Koeffizientenvergleich erkennt man sofort, dass $p_1 = p_2 = \frac{1}{2}$ sein muss, damit die Dichten Übereinstimmen. In anderen Worten stimmt die Verteilung von $(P_1, 1 - P_1) \sim GEM(-1, 2)$ nach einer uniformen Permutation mit $(U, 1 - U)$ überein. Da $(P_1, P_2) \sim PD(-1, 2)$ eine absteigende Anordnung von $(P_1, P_2) \sim GEM(-1, 2)$ (nach Definition 6), ist $PD(-1, 2)$ eine absteigende Anordnung und somit eine Permutation von $(U, 1 - U)$. Falls wir $(P_1, 1 - P_1) \sim PD(-1, 2)$ definieren,

können wir die Verteilung von P_1 mit $a \in [0, 1]$ bestimmen

$$\begin{aligned}\mathbb{P}(\max(U, 1 - U) \leq a) &= \mathbb{P}(U \leq a \cap 1 - U \geq a) \\ &= \mathbb{P}(1 - a \leq U \leq a) = \mathbb{P}(U \leq 2a - 1) \\ &= \begin{cases} 0 & a < 0.5 \\ 2a - 1 & 0.5 \leq a \leq 1 \\ 1 & 1 > a \end{cases}\end{aligned}$$

und somit ist $PD(-1, 2) \stackrel{\mathcal{L}}{=} U(\frac{1}{2}, 1)$.

Die Betrachtungsweise von $T_n^{-1,m}$, als geordnete Bäume lässt sich auch auf $m > 2$ verallgemeinern. Diesmal betrachten vollständige $\mathcal{T}_m$ Bäume, mit Kindern von einem Knoten mit $\{1, \dots, m\}$ beschriftet und dann zufällig Uniform permutiert, wieder wird $(T_n^{-1,m})_{n \in \mathbb{N}}$ in $\mathcal{T}_m$ eingebettet und in jedem Schritt ein externer Knoten von $(T_n^{-1,m})_{n \in \mathbb{N}}$ mit Beschriftung in $\mathcal{T}_m$ uniform ausgewählt und hinzugefügt. Diese geordnete Konstruktion von einem Baum wird mit *m-ary increasing tree* bezeichnet. Wir bestimmen jetzt den Split Vektor welcher den *m-ary increasing tree* auch für $m > 2$ charakterisiert.

Satz 4.1. *Sei $m \geq 2$. Die Folge von linear preferential attachment trees $(T_n^{-1,m})_{n \in \mathbb{N}}$, betrachtet als m-ary increasing Trees haben dieselbe Verteilung wie die Folge der Split Bäume $(T_n^{\mathcal{P}})_{n \in \mathbb{N}}$, mit*

$$\mathcal{P} = (P_i)_{i \in \mathbb{N}} \sim \text{Dir}\left(\frac{1}{m-1}, \dots, \frac{1}{m-1}\right),$$

wobei mit *Dir* die Dirichlet-Verteilung gemeint ist.

Definition 9. Dirichlet-Verteilung

Ein Wahrscheinlichkeitsvektor $(X_1, \dots, X_m)$ ($\sum_{i=1}^m X_i \geq 0$ und $X_i \geq 0$) der Länge m ist $\text{Dir}(\alpha_1, \dots, \alpha_m)$ verteilt, falls die Wahrscheinlichkeitsdichte durch

$$f(x_1, \dots, x_m) = \frac{\Gamma(\sum_{i=1}^m x_i)}{\prod_{i=1}^m \Gamma(x_i)} \prod_{i=1}^m x_i^{\alpha_i - 1}$$

für $x_i \geq 0$ und $\sum_{i=1}^m x_i = 1$ und für sonstige $(x_1, \dots, x_m)$ durch 0 gegeben ist.

Beweis von Satz 4.1. Wir beginnen mit der Existenz vom Split Vektor $\mathcal{P}$. Aus Satz 2.3 folgt, dass $T_n^{-1,m} \stackrel{\mathcal{L}}{=} T_n^{\mathcal{P}}$, mit $\mathcal{P} \sim PD(-\frac{1}{m-1}, \frac{m}{m-1})$, falls wir beide Bäume als ungeordnet interpretieren. Zur Überführung in dem geordneten Fall betrachte man eine zufällige uniforme Permutation von $\mathcal{P}$, bezeichnet mit $\tilde{\mathcal{P}}$. In diesem Fall ist durch Symmetrie sowohl im ungeordneten als auch im geordneten Fall $T_n^{-1,m} \stackrel{\mathcal{L}}{=} T_n^{\tilde{\mathcal{P}}}$, denn beide Bäume sind invariant unter zufälligen Umbenennungen von allen Kindern der Knoten.

Es fehlt zu zeigen, dass diese Permutation von einer *PD* Verteilung, tatsächlich einer *Dir* Verteilung entspricht. Wir definieren für ein *principal subtree* T_n^j , $N_j(n) := |T_n^j|$ als Anzahl der Knoten und $N_j^e(n)$ als Anzahl der externen Knoten von T_n^j . Dann ist $N_j^e(n) = (m-1)N_j(n) + 1$ durch eine einfache Induktion, denn für jeden zusätzlichen Knoten der zu T_n^j hinzukommt, kommen von diesem Knoten aus zusätzliche m externe

Knoten hinzu und ein externer Knoten wird durch den hinzugekommenen Knoten ersetzt. Wir interpretieren jetzt $T_n^{-1,m}$ wieder als ungeordneten Baum und identifizieren die externen Knoten im *principal Subtree* T_n^j als Bälle mit Farbe j . Die Anzahl der externen Knoten mit Farbe j folgen jetzt einem Polya Urnen Prozess. Am Anfang gibt es in der Urne einen Ball von jeder Farbe (Der Baum besteht nur aus der Wurzel) und in jedem Schritt wird ein zufälliger Ball gezogen und anschließend mit $m - 1$ zusätzlichen Bälle derselben Farbe in die Urne zurückgelegt. Dieser Art von verallgemeinerten Polya Urnen Prozess wurde in [2] untersucht und bezogen auf unsern Fall, konvergiert

$$\left(\frac{N_j^e(n)}{(m-1)n+1} \right)_{j \in \{1 \dots m\}} = \left(\frac{(m-1)N_j(n)+1}{(m-1)n+1} \right)_{j \in \{1 \dots m\}} \rightarrow (X_j)_{j \in \{1 \dots m\}} \text{ P-f.s. für } n \rightarrow \infty,$$

mit $(X_j)_{j \in \{1 \dots m\}} \sim \text{Dir}(\frac{1}{m-1}, \dots, \frac{1}{m-1})$.

Insbesondere folgt $N_j(n)/n \rightarrow (X_j)$ P-f.s. Dieser Grenzwert ist aber bereits der Grenzwert der unseren Wahrscheinlichkeitsvektor liefert. Denn ähnlich zu Satz 2.4, liefert uns das Gesetz der großen Zahlen, gegeben den Split Vektor an der Wurzel,

$$\frac{N_j(n)}{n} \rightarrow P_j \text{ P-f.s. für } n \rightarrow \infty \quad \forall j \in \{1 \dots m\}.$$

In anderen Worten ist $(P_j)_{j \in \{1 \dots m\}} \sim \text{Dir}(\frac{1}{m-1}, \dots, \frac{1}{m-1})$ und die Behauptung ist gezeigt. $\square$

Anhang

Lemma 4.2. Die Anzahl der Partitionen von $[n]$ mit Klassengröße in Reihenfolge ihres Erscheinens ist durch 1.2 gegeben.

Beweis. Das $\#(\mathbf{n})$ tatsächlich die Form 1.2 hat, lässt sich durch Betrachtung von

$$\begin{aligned} \Omega_{\mathbf{n}} = \{ \mathbf{x} := (x_{n_1}^1, x_{n_1}^2, \dots, x_{n_1}^{n_1}, x_{n_2}^1, x_{n_2}^2, \dots, x_{n_k}^{n_k}) \mid \mathbf{n} := (n_1, \dots, n_k), \sum_{i=1}^k n_i = n \\ , \mathbf{x} \in \mathcal{P}(n) \\ , x_{n_i}^j < x_{n_i}^{j+1} \quad \forall i \in \{1 \dots k\} \forall j \in \{1 \dots n_i - 1\} \\ , x_{n_i}^1 < x_{n_i+1}^1 \quad \forall i \in \{1 \dots k\} \} \end{aligned}$$

nachweisen. Es gilt

$$\#(\mathbf{n}) = |\Omega_{\mathbf{n}}|$$

und wir berechnen nun $|\Omega_{\mathbf{n}}|$. Es gibt $n!$ Möglichkeiten $[n]$ zu permutieren, nach den Bedingungen von $\Omega_{\mathbf{n}}$ muss aber $x_{n_i}^1$ für alle i kleiner sein als jede darauffolgende Zahl in der Liste. Formal beschrieben bedeutet das, falls $\mathbf{x}_i, 1 \leq i \leq n$ die i -te Komponente von $\mathbf{x}$ ist, so ist $\mathbf{x}_{n_i} < \mathbf{x}_j \quad \forall i \in \{n_i + 1, \dots, n\}$. Sei

$$\begin{aligned} \Omega_{\mathbf{n}}^1 = \{ \mathbf{x} := (x_{n_1}^1, x_{n_1}^2, \dots, x_{n_1}^{n_1}, x_{n_2}^1, x_{n_2}^2, \dots, x_{n_k}^{n_k}) \mid \mathbf{n} := (n_1, \dots, n_k), \sum_{i=1}^k n_i = n \\ , \mathbf{x} \in \mathcal{P}(n) \\ , \mathbf{x}_{n_i} < \mathbf{x}_j \quad \forall i \in \{1 \dots k\}, \forall j \in \{n_i + 1, \dots, n\} \} \end{aligned}$$

so ist

$$|\Omega_{\mathbf{n}}^1| = \frac{n!}{n(n - n_1)(n - n_2 - n_1) \dots (n - \sum_{i=1}^{k-1} n_i)}.$$

Um von $|\Omega_{\mathbf{n}}^1|$ auf $|\Omega_{\mathbf{n}}|$ zu kommen fehlt uns in jedem der einzelnen Komponenten n_i die Permutationen der $n_i - 1$ nachfolgenden Zahlen nach jedem der $\mathbf{x}_{n_i}$ zu zählen. Da es aber $\prod_{i=1}^k (n_i - 1)!$ davon gibt, gilt

$$|\Omega_{\mathbf{n}}| = \frac{|\Omega_{\mathbf{n}}^1|}{\prod_{i=1}^k (n_i - 1)!}$$

und die Behauptung ist gezeigt. □

Lemma 4.3. *Damit ein Paar (α, θ) einen wohldefinierten chinese restaurant process definiert, muss (α, θ) eine von folgenden beiden Bedingungen erfüllen:*

1. $0 \leq \alpha < 1$ und $\theta > -\alpha$
2. $\alpha < 0$ und $\theta = -m\alpha$ für ein $m \in \mathbb{N}$.

Beweis. Es muss geprüft werden, ob $\frac{n_j - \alpha}{n + \theta}$ und $\frac{\theta + k\alpha}{n + \theta}$ stets zwischen 0 und 1 liegen. Wir betrachten jetzt 5 Beispielfälle einzeln, die restlichen folgen mit analogen Argumenten.

Fall 1: $\alpha = 1$

Dies entspricht dem Fall, dass jeder Gast an einen neuen Tisch gesetzt wird. Falls wir die Beta Verteilung um $\beta(0, l) = \delta_0, l \in \mathbb{R}$, also die deterministische Zufallsvariable mit Wert 0 erweitern, so gilt Satz 1.8 auch für diesen Fall. Die dazugehörige Folge $(P_1, P_2, \dots)$ wäre dann die 0 Folge.

Fall 2: $\alpha > 1$ und $-1 < \theta < 0$

Bei $n = 1$ ist $k = 1$ und somit

$$\frac{\theta + k\alpha}{n + \theta} = \frac{\theta + \alpha}{1 + \theta} > 1$$

Fall 3: $\alpha > 1$ und $\theta \neq -l\alpha, l \in \mathbb{N}$

In diesem Fall wollen wir zeigen, dass

$$\frac{n_j - \alpha}{n + \theta} < 0$$

für mögliche $n_j \in \mathbb{N}$. Es reicht, falls wir zeigen, dass für alle $n \in \mathbb{N}$ wir eine Anordnung von Tischen finden, sodass mindestens ein Tisch mit nur einem Gast besetzt ist. Dann würden $n \in \mathbb{N}$ existieren, nämlich $\forall n > \lceil l\alpha \rceil$, sodass

$$\frac{n_j - \alpha}{n + \theta} = \frac{1 - \alpha}{n + \theta} < 0.$$

Nun ist für jede mögliche Anordnung von Tischen mit n Gästen, die Wahrscheinlichkeit einen neuen Tisch zu beschaffen $\frac{\theta + k\alpha}{n + \theta} \neq 0$ und somit wird es im nächsten Schritt ein Tisch mit nur einem Gast geben. Dieser Fall ist deshalb ausgeschlossen.

Fall 4: $\alpha > 1$ und $\theta = -\alpha$

Dieser Fall ist Analog zu dem Fall $\alpha < 0$ und $-m\alpha$ und Satz 1.8 kann auch mit diesem Fall erweitert werden.

Fall 5: $\alpha > 1$ und $\theta = -l\alpha, l \geq 2, l \in \mathbb{N}$

Wir schließen zuerst den Fall $-\theta \in \mathbb{N}$ aus, in diesem Fall würde es für ein $n \in \mathbb{N}$ zu dem Fall kommen, wo der Nenner gleich 0 und somit undefiniert wäre. Infolgedessen, ist auch $\alpha \notin \mathbb{N}$, denn wenn $\alpha \in \mathbb{N}$, dann auch $-\theta \in \mathbb{N}$ wäre.

Wir betrachten nun die Anordnung wo jeder Gast sich an den ersten Tisch setzt. Die Wahrscheinlichkeit, dass sich der $(n+1)$ -te Gast sich an den ersten Tisch setzt, da $n_j = n$, ist

$$\frac{n - \alpha}{n - l\alpha}.$$

Nach der ersten Bemerkung, dass $\alpha \notin \mathbb{N}$, ist diese Wahrscheinlichkeit nie 0, also muss

$$0 < \frac{n - \alpha}{n - l\alpha} \leq 1.$$

Da aber es eine natürliche Zahl n geben muss, die zwischen α und $l\alpha$ liegt, ist die Wahrscheinlichkeit für diese Zahl < 0 und somit ist diese Möglichkeit auch nicht zulässig.

Die restlichen Fälle können mit analogen Argumenten geprüft werden. □

Literaturverzeichnis

- [1] David J Aldous, Illdar A Ibragimov, and Jean Jacod. *Ecole d'Ete de Probabilites de Saint-Flour XIII, 1983*, volume 1117. Springer, 2006.
- [2] Krishna B Athreya. On a characteristic property of pólya's urn. *Studia Sci. Math. Hungar*, 4:31–35, 1969.
- [3] P Billingsley. Probability and measure. 3rd wiley. *New York*, 1995.
- [4] Luc Devroye. Universal limit laws for depths in random trees. *SIAM Journal on Computing*, 28(2):409–432, 1998.
- [5] Wassily Hoeffding. The strong law of large numbers for u-statistics. Technical report, North Carolina State University. Dept. of Statistics, 1961.
- [6] Svante Janson. Random recursive trees and preferential attachment trees are random split trees. *Combinatorics, Probability and Computing*, 28(1):81–99, 2019.
- [7] Norman L Johnson, Samuel Kotz, and Narayanaswamy Balakrishnan. *Continuous univariate distributions, volume 2*, volume 289. John wiley & sons, 1995.
- [8] John FC Kingman. The representation of partition structures. *Journal of the London Mathematical Society*, 2(2):374–380, 1978.
- [9] John Frank Charles Kingman. The coalescent. *Stochastic processes and their applications*, 13(3):235–248, 1982.
- [10] Alois Panholzer and Helmut Prodinger. Level of nodes in increasing trees revisited. *Random Structures & Algorithms*, 31(2):203–226, 2007.
- [11] Jim Pitman. Exchangeable and partially exchangeable random partitions. *Probability theory and related fields*, 102(2):145–158, 1995.
- [12] Jim Pitman. *Combinatorial stochastic processes: Ecole d'été de probabilités de saint-flour xxxii-2002*. Springer, 2006.